Laporan Tugas Praktikum 4: Association Rule

Analisis Keranjang Belanja pada Dataset Online Retail dengan Algoritma Apriori dan FP-Growth

Nama	Fauzan Tamma Harish Kunfaza	**Mata Kuliah**	Data Mining (Praktikum 4)
NRP	5054251035	**Program Studi**	Rekayasa Kecerdasan Artifisial, ITS

1. Pendahuluan

Association Rule mining menemukan pola “jika pelanggan membeli A maka ia cenderung membeli C” dari data transaksi. Pada praktikum ini dataset **Online Retail** (UCI Machine Learning Repository; transaksi ritel online di Inggris, Desember 2010 sampai Desember 2011; 541.909 baris dan 8 kolom) dianalisis menggunakan algoritma **Apriori** yang diverifikasi dengan **FP-Growth**. Aturan dievaluasi dengan tiga metrik:

- **Support** = P(A ∩ C), proporsi transaksi yang memuat A dan C sekaligus.
- **Confidence** = P(C | A), peluang C dibeli bila A sudah berada di keranjang.
- **Lift** = confidence / P(C); nilai > 1 berarti A dan C dibeli bersamaan lebih sering daripada kebetulan (saling melengkapi).

Item yang dianalisis adalah produk (**Description**) dan satu transaksi adalah satu invoice (**InvoiceNo**).

2. Eksplorasi dan Pembersihan Data

2.1 Kondisi data awal

Pemeriksaan awal pada data mentah menemukan masalah berikut:

- **1.454** baris dengan *Description* kosong (0,27%); kolom *CustomerID* kosong 24,9% (tidak dipakai).
- **9.288** baris (3.836 invoice) merupakan transaksi dibatalkan (InvoiceNo berawalan “C”).
- **10.624** baris dengan *Quantity* ≤ 0 (retur dan penyesuaian stok).
- Nama produk yang sama tertulis berbeda (spasi di ujung, huruf besar/kecil), serta ada baris non-produk (ongkos kirim, biaya bank, *manual*, voucher) dan baris dengan *UnitPrice* ≤ 0.

2.2 Proses pembersihan dan jumlah baris/invoice sebelum–sesudah

Tiga langkah pertama adalah langkah wajib dari ketentuan tugas; tiga langkah berikutnya adalah tambahan agar item yang dianalisis bersih dan konsisten.

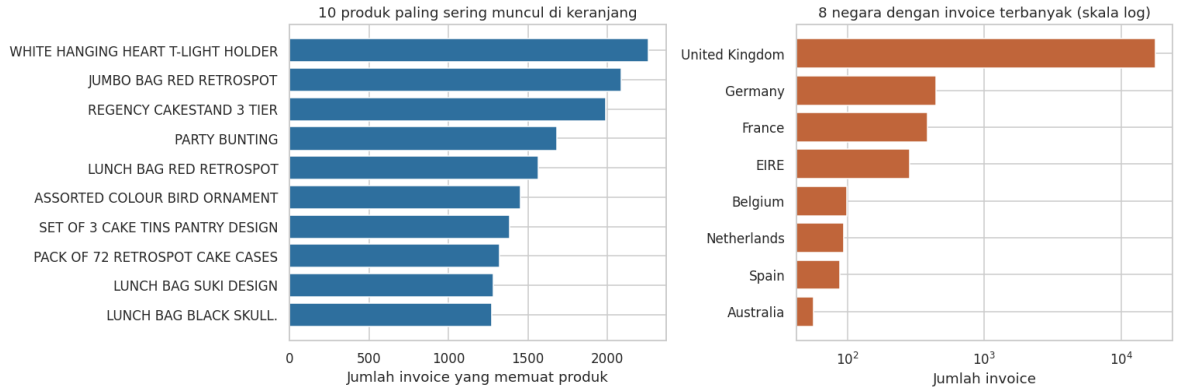
Langkah	Baris	Invoice	Baris terhapus	Invoice terhapus
Data awal	541.909	25.900	0	0
Hapus Description kosong	540.455	24.446	1.454	1.454
Hapus invoice dibatalkan (awalan 'C')	531.167	20.610	9.288	3.836
Hapus Quantity <= 0	530.693	20.136	474	474
Normalisasi nama produk (strip/huruf besar) & hapus nama kosong	530.693	20.136	0	0
Hapus baris non-produk (postage, manual, bank charges, voucher, dll.)	528.336	19.954	2.357	182
Hapus UnitPrice <= 0	527.759	19.773	577	181

Tabel 1. Log pembersihan data.

	Sebelum	Sesudah	Berkurang
Jumlah baris	541.909	527.759	2,61%
Jumlah invoice (transaksi)	25.900	19.773	23,66%

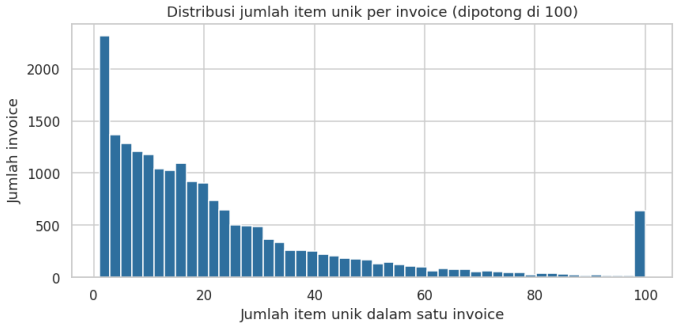
Tabel 2. Ringkasan sebelum dan sesudah pembersihan. Produk unik setelah pembersihan: 3.994.

2.3 Eksplorasi setelah pembersihan



Gambar 1. Produk yang paling sering muncul dalam keranjang dan sebaran invoice per negara.

Produk terlaris adalah *White Hanging Heart T-Light Holder* (±11,4% transaksi), diikuti *Jumbo Bag Red Retrospot* dan *Regency Cakestand 3 Tier*. Sebanyak **90,5%** invoice berasal dari United Kingdom. Keranjang rata-rata berisi ±26 produk unik (median 15), sehingga pelanggan dataset ini berkarakter pedagang grosir yang membeli banyak jenis sekaligus.



Gambar 2. Distribusi jumlah item unik per invoice (dipotong di 100).

3. Persiapan Data untuk Association Rule

Data diubah menjadi transaksi berbasis invoice (daftar produk per invoice) setelah duplikat pasangan (invoice, produk) dihapus, kemudian dikonversi menjadi matriks **one-hot** (baris = invoice, kolom = produk, nilai benar/salah). Matriks akhir berukuran **19.773 transaksi × 3.994 produk** dengan kepadatan hanya ±0,66%, yaitu data sangat jarang. Kuantitas pembelian tidak digunakan karena Association Rule hanya memperhatikan ada tidaknya item dalam keranjang.

4. Penerapan Algoritma

Algoritma Apriori dijalankan dengan titik awal yang ditentukan tugas, yaitu **minimum support 0,01** (≥ 198 invoice) dan **minimum confidence 0,5**. Hasilnya:

- **1.892 frequent itemset**: 822 berisi 1 produk, 819 berisi 2 produk, 228 berisi 3 produk, 22 berisi 4 produk, dan 1 berisi 5 produk.
- **879 aturan asosiasi** (confidence ≥ 0,5). FP-Growth menghasilkan itemset dan nilai support yang **identik** dengan Apriori.

4.1 Penyesuaian parameter

Jumlah aturan diuji pada beberapa kombinasi support dan confidence untuk menilai apakah titik awal perlu diubah:

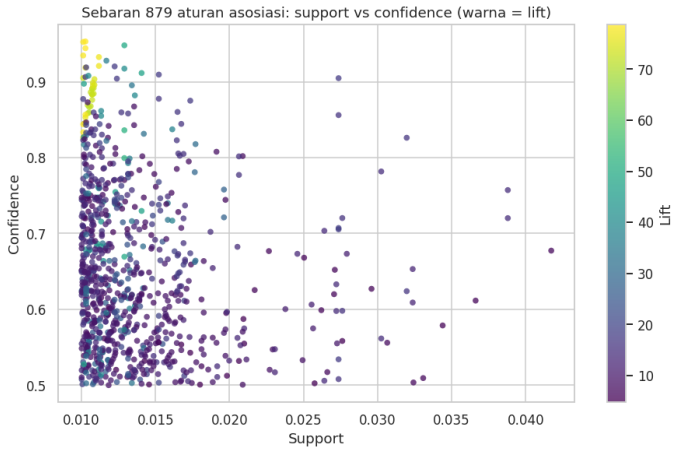
min. support \ min. confidence	0,5	0,6	0,7
0,010	879	540	274
0,015	207	106	47
0,020	60	30	13
0,030	14	9	4

Tabel 3. Jumlah aturan asosiasi pada berbagai kombinasi parameter.

Keputusan: parameter awal (support 0,01; confidence 0,5) dipertahankan. Dengan ±19.800 transaksi, support 0,01 berarti pola harus muncul di sekitar 198 invoice, cukup untuk menyaring kebetulan statistik namun masih menangkap produk niche (katalog memuat ±4.000 produk sehingga support tiap produk kecil). Menaikkan support menjadi 0,02–0,03 menyisakan hanya 14–60 aturan yang didominasi produk terlaris dan membuang banyak pola antar-produk, sedangkan menaikkan confidence ke 0,7 memangkas aturan secara drastis (879 menjadi 274). Jumlah 879 aturan masih dapat dianalisis, sehingga parameter tidak diubah.

5. Evaluasi Aturan Asosiasi

Seluruh 879 aturan memiliki lift > 1 (minimum 4,74; median 12,31; maksimum 78,77) dan confidence antara 0,50 sampai 0,95 (median 0,63); support berkisar 0,010–0,042. Tidak ada aturan dengan hubungan negatif.



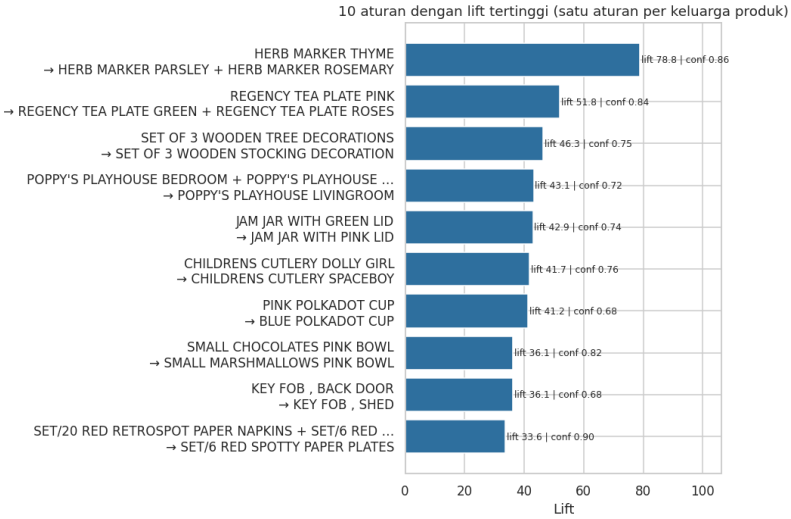
Gambar 3. Sebaran aturan: support vs confidence, warna menunjukkan lift. Aturan lift tinggi berada di support rendah (±1%).

5.1 Aturan dengan lift tertinggi

Antecedent (A)	Consequent (C)	Support	Confidence	Lift
HERB MARKER THYME	HERB MARKER PARSLEY + HERB MARKER ROSEMARY	0.0103	0.857	78.77
HERB MARKER PARSLEY + HERB MARKER ROSEMARY	HERB MARKER THYME	0.0103	0.944	78.77
HERB MARKER PARSLEY + HERB MARKER THYME	HERB MARKER ROSEMARY	0.0103	0.953	78.52
HERB MARKER ROSEMARY	HERB MARKER PARSLEY + HERB MARKER THYME	0.0103	0.846	78.52
HERB MARKER BASIL + HERB MARKER THYME	HERB MARKER ROSEMARY	0.0101	0.952	78.46
HERB MARKER ROSEMARY	HERB MARKER BASIL + HERB MARKER THYME	0.0101	0.833	78.46

Tabel 4. Enam aturan teratas menurut lift. Seluruhnya berasal dari keluarga Herb Marker dan saling berulang (arah A→C dan C→A, atau permutasi itemset yang sama).

Karena pengurutan murni berdasarkan lift didominasi satu keluarga produk dengan aturan kembar, pemilihan tiga aturan terbaik dilakukan bertahap: (1) urutkan menurut lift (tie-break confidence); (2) ambil satu aturan terbaik per itemset; (3) ambil satu aturan terbaik per keluarga produk (kata pertama ≥ 4 huruf yang dimiliki bersama semua produk dalam aturan); (4) ambil tiga teratas.



Gambar 4. Sepuluh aturan dengan lift tertinggi (satu aturan per keluarga produk).

5.2 Tiga aturan terbaik

#	Antecedent (A)	Consequent (C)	Support	Invoice	Conf.	Lift
1	HERB MARKER THYME	HERB MARKER PARSLEY + HERB MARKER ROSEMARY	0.0103	203	0.857	78.77
2	REGENCY TEA PLATE PINK	REGENCY TEA PLATE GREEN + REGENCY TEA PLATE ROSES	0.0129	255	0.836	51.82
3	SET OF 3 WOODEN TREE DECORATIONS	SET OF 3 WOODEN STOCKING DECORATION	0.0111	219	0.747	46.33

Tabel 5. Tiga aturan terbaik berdasarkan lift (satu per keluarga produk).

#	P(A)	P(C)	P(A,C) = support	P(C|A) = confidence	Lift = P(C|A)/P(C)
1	0.0120	0.0109	0.0103	0.857	78.77
2	0.0154	0.0161	0.0129	0.836	51.82
3	0.0148	0.0161	0.0111	0.747	46.33

Tabel 6. Dekomposisi lift: peluang bersyarat dibanding peluang dasar.

5.3 Interpretasi dalam konteks bisnis ritel

Aturan 1: Herb Marker Thyme → Herb Marker Parsley + Herb Marker Rosemary (support 0,0103 ≈ 203 invoice; confidence 0,857; lift 78,8). Peluang dasar membeli parsley dan rosemary bersamaan hanya ±1,09%, tetapi bila thyme sudah dibeli peluangnya menjadi 85,7%, yaitu ±79 kali lebih besar. Produk ini tampaknya merupakan satu seri penanda tanaman herba yang dibeli sebagai koleksi. Implikasi: tawarkan **paket lengkap herb marker** dan tampilkan seluruh varian berdampingan.

Aturan 2: Regency Tea Plate Pink → Regency Tea Plate Green + Regency Tea Plate Roses (support 0,0129 ≈ 255 invoice; confidence 0,836; lift 51,8). Pembeli piring pink umumnya melengkapi varian hijau dan *roses* (peluang dasar ±1,6%). Ini pola **melengkapi set warna** satu desain; cocok untuk rekomendasi “lengkapi koleksi” pada keranjang belanja dan untuk menjaga ketersediaan stok ketiga varian secara bersamaan.

Aturan 3: Set of 3 Wooden Tree Decorations → Set of 3 Wooden Stocking Decoration (support 0,0111 ≈ 219 invoice; confidence 0,747; lift 46,3). Keduanya dekorasi Natal. Analisis bulan transaksi menunjukkan **82,6%** invoice aturan ini terjadi pada September–November, dibanding 33,2% pada seluruh invoice, sehingga pola ini musiman. Implikasi: paket dekorasi Natal

dan penambahan stok perlu disiapkan sebelum kuartal terakhir.

Aturan dengan support tinggi. Pola yang menjangkau transaksi lebih banyak walau lift lebih rendah, misalnya *Jumbo Bag Pink Polkadot* → *Jumbo Bag Red Retrospot* (support 0,042 ≈ 825 invoice; confidence 0,677; lift 6,4) dan *Green Regency Teacup and Saucer* ↔ *Roses Regency Teacup and Saucer* (support 0,039; confidence 0,72–0,76; lift 14,1). Cakupan transaksinya ±4 kali lebih luas sehingga relevan untuk penataan produk dan promosi paket tas jumbo serta cangkir-piring Regency.

Catatan membaca lift. Lift yang sangat tinggi muncul karena produk konsekuen jarang dibeli (peluang dasar ±1%), sehingga lift harus dibaca bersama support dan jumlah invoice (200–255 invoice per aturan di atas), bukan sendirian.

6. Kesimpulan

Pembersihan mengubah 541.909 baris (25.900 invoice) menjadi 527.759 baris dalam **19.773 transaksi** dengan **3.994 produk unik**. Apriori dengan support 0,01 dan confidence 0,5 menghasilkan **1.892 frequent itemset** dan **879 aturan asosiasi** yang seluruhnya berlift > 1; FP-Growth memberikan hasil yang identik. Pola yang ditemukan dapat diringkas menjadi tiga:

- **Pelengkap satu seri/varian produk** (herb marker, piring dan cangkir teh Regency, Poppy’s Playhouse, jam jar, peralatan makan anak): pembeli satu varian sangat mungkin membeli varian lainnya, dengan lift 40–79.
- **Pola musiman Natal**: dekorasi kayu Natal terkonsentrasi pada September–November.
- **Produk terlaris sekeluarga** (tas jumbo dan lunch bag) memiliki support 3–4% sehingga berdampak luas meski lift moderat (5–7).

Rekomendasi bisnis: bundling “set lengkap” untuk produk satu seri, rekomendasi cross-selling di keranjang belanja, penataan produk bervarian berdekatan, serta penyiapan stok dan promosi dekorasi Natal sebelum kuartal terakhir.

Keterbatasan. (1) Aturan terkuat umumnya hubungan antarvarian dalam satu seri produk sehingga sebagian bersifat “sudah wajar”; hubungan lintas kategori memerlukan support lebih rendah atau pengelompokan produk ke kategori. (2) Lift membesar pada produk bersupport kecil. (3) Pelanggan dataset sebagian besar grosir di Inggris sehingga pola belum tentu berlaku untuk pembeli eceran atau negara lain. (4) Association Rule menunjukkan keterkaitan, bukan hubungan sebab-akibat.

Seluruh kode, keluaran, dan analisis lengkap tersedia pada notebook pendamping *5054251035_Fauzan_Tamma_Harish_Kunfaza_Tugas_Association_Rule.ipynb*.