LAPORAN TUGAS PRAKTIKUM 3

Klasifikasi dengan Ensemble Method dan Penanganan Class Imbalance pada Deteksi Fraud Kartu Kredit

Nama	Fauzan Tamma Harish Kunfaza	**NRP**	5054251035
Program Studi	Rekayasa Kecerdasan Artifisial, Institut Teknologi Sepuluh Nopember (ITS)	**Dataset**	Credit Card Fraud Detection (Kaggle)

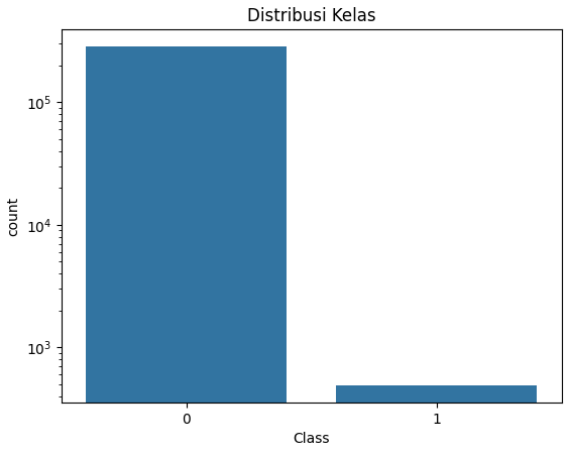
1. Pendahuluan

Praktikum ini membangun model klasifikasi berbasis *ensemble method* pada data yang distribusi kelasnya sangat tidak seimbang, lalu membandingkan beberapa teknik penanganan *class imbalance*. Studi kasusnya adalah deteksi transaksi penipuan (*fraud*) pada dataset *Credit Card Fraud Detection* dari Kaggle, yang memuat transaksi kartu kredit pemegang kartu di Eropa selama dua hari. Label target **Class** bernilai 0 untuk transaksi normal dan 1 untuk fraud.

Tujuan praktikum: (1) menerapkan *Random Forest* sebagai ensemble method untuk klasifikasi; (2) menangani class imbalance dengan *cost-sensitive learning* (`class_weight`), *oversampling* (SMOTE), dan *undersampling*; serta (3) mengevaluasi model dengan metrik yang sesuai untuk data tidak seimbang, yaitu precision, recall, F1-score, ROC-AUC (ditambah PR-AUC), dan confusion matrix. Alur pengerjaan: memuat data, memeriksa distribusi kelas, membagi data 80:20 secara terstratifikasi, melakukan resampling **hanya pada data latih**, melatih empat model Random Forest, mengevaluasi seluruhnya pada data uji asli, kemudian menganalisis hasilnya.

2. Hasil Distribusi Kelas Awal

Dataset berukuran **284.807 baris × 31 kolom**. Seluruh kolom bertipe numerik dan tidak terdapat *missing value*. Fitur `V1–V28` adalah hasil transformasi PCA (makna aslinya dirahasiakan demi privasi), sedangkan `Time` (detik sejak transaksi pertama) dan `Amount` (nominal transaksi) adalah fitur asli. Terdapat 1.081 baris duplikat (19 di antaranya fraud) yang sengaja **tidak dihapus** agar distribusi data tetap sesuai aslinya. Nilai `Amount` sangat miring ke kanan (rata-rata ≈ 88, median 22, maksimum 25.691).



Tabel 1. Distribusi kelas pada seluruh dataset

Kelas	Jumlah	Persentase
0 (normal)	284.315	99,827%
1 (fraud)	492	0,173%
Total	**284.807**	**100%**

Rasio kelas normal : fraud ≈ **578 : 1**. Fraud hanya **0,17%** dari seluruh transaksi, sehingga ini merupakan kasus class imbalance yang ekstrem.

Gambar 1. Distribusi kelas (sumbu-y berskala logaritmik agar batang fraud tetap terlihat)

Ketimpangan ini berdampak langsung pada pelatihan model: tanpa penanganan, model cenderung condong ke kelas mayoritas karena kesalahan pada kelas fraud hampir tidak memengaruhi rata-rata kesalahan keseluruhan.

3. Pendekatan Penanganan Class Imbalance

3.1 Pembagian data

Data dibagi menjadi data latih dan data uji dengan perbandingan **80:20** menggunakan `stratify=y` dan `random_state=42` sehingga proporsi fraud terjaga di kedua bagian. Fitur tidak di-*scaling* karena Random Forest berbasis pohon keputusan yang hanya bergantung pada urutan nilai fitur.

Tabel 2. Hasil pembagian data latih dan data uji

Bagian data	Jumlah transaksi	Fraud	Proporsi fraud
Data latih (80%)	227.845	394	0,173%
Data uji (20%)	56.962	98	0,172%

Data uji hanya berisi **98 fraud**, sehingga metrik kelas fraud cukup sensitif: selisih satu transaksi menggeser recall sekitar 1 poin persentase.

3.2 Teknik penanganan imbalance

Tiga pendekatan dibandingkan dengan model tanpa penanganan (*baseline*). **Resampling dilakukan hanya pada data latih** (setelah split), sedangkan data uji dibiarkan dengan distribusi aslinya agar evaluasi mencerminkan kondisi nyata dan tidak terjadi *data leakage*.

Tabel 3. Teknik penanganan class imbalance yang digunakan

Pendekatan	Cara kerja	Data latih setelah perlakuan
Cost-sensitive `class_weight="balanced_subsample"`	Kesalahan pada kelas fraud diberi bobot lebih besar saat pohon dibangun; data tidak diubah.	227.451 normal : 394 fraud (tidak berubah)
SMOTE (oversampling)	Membuat sampel fraud sintetis lewat interpolasi antar tetangga terdekat.	227.451 : 227.451 (total 454.902, membesar ±2×)
Random undersampling	Membuang sebagian besar sampel normal hingga jumlahnya sama dengan fraud.	394 : 394 (total 788, menyusut drastis)

3.3 Model ensemble

Random Forest dipilih karena menggabungkan banyak pohon keputusan (*bagging*) sehingga lebih stabil dan tahan *overfitting* dibanding satu pohon, serta bekerja baik pada data tabular. Empat model dilatih dengan hyperparameter yang sama (`n_estimators=100`, `random_state=42`), sehingga perbedaan hasil hanya berasal dari cara penanganan imbalance: (1) **RF Baseline** pada data latih asli, (2) **RF class_weight** pada data latih asli dengan bobot kelas, (3) **RF + SMOTE**, dan (4) **RF + Undersample**.

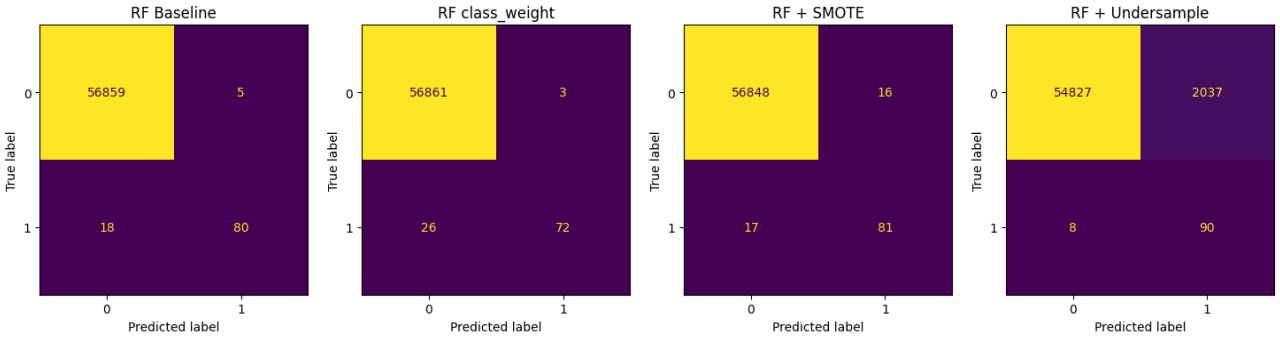
4. Performansi Model dan Metrik Evaluasi

Seluruh model dievaluasi pada **data uji asli** (56.962 transaksi; 56.864 normal dan 98 fraud) dengan fraud sebagai kelas positif. Metrik yang dipakai: **precision** = TP/(TP+FP), yaitu ukuran *false alarm*; **recall** = TP/(TP+FN), yaitu ukuran fraud yang berhasil terdeteksi; **F1-score**, rata-rata harmonik precision dan recall; **ROC-AUC**, kemampuan memisahkan kedua kelas di semua threshold (cenderung optimistis pada data sangat tidak seimbang); serta **PR-AUC** (*average precision*), ringkasan kurva precision-recall yang lebih peka terhadap kelas minoritas.

Tabel 4. Metrik evaluasi kelas fraud pada data uji (nilai terbaik per kolom diberi warna hijau)

Model	Precision	Recall	F1	ROC-AUC	PR-AUC
RF Baseline	0,9412	0,8163	**0,8743**	0,9630	0,8734
RF class_weight	**0,9600**	0,7347	0,8324	0,9529	0,8597
RF + SMOTE	0,8351	0,8265	0,8308	0,9644	**0,8747**
RF + Undersample	0,0423	**0,9184**	0,0809	**0,9777**	0,6953

4.1 Confusion matrix

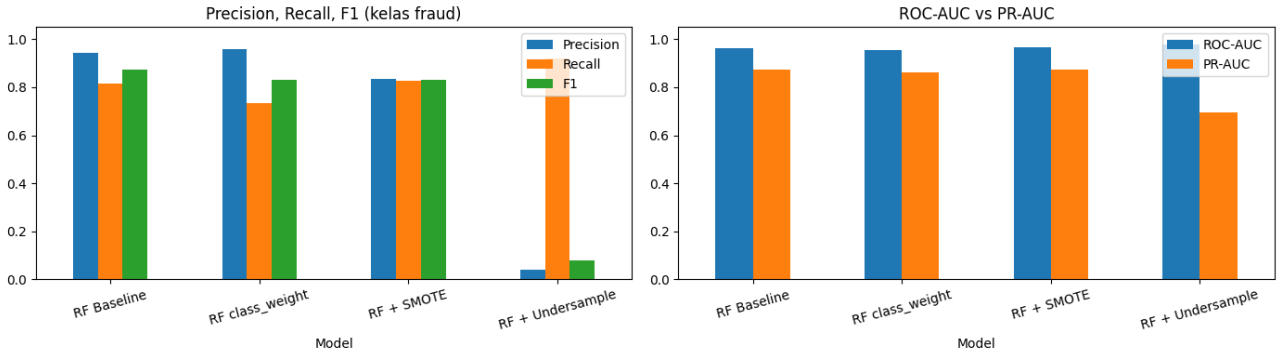


Gambar 2. Confusion matrix keempat model pada data uji

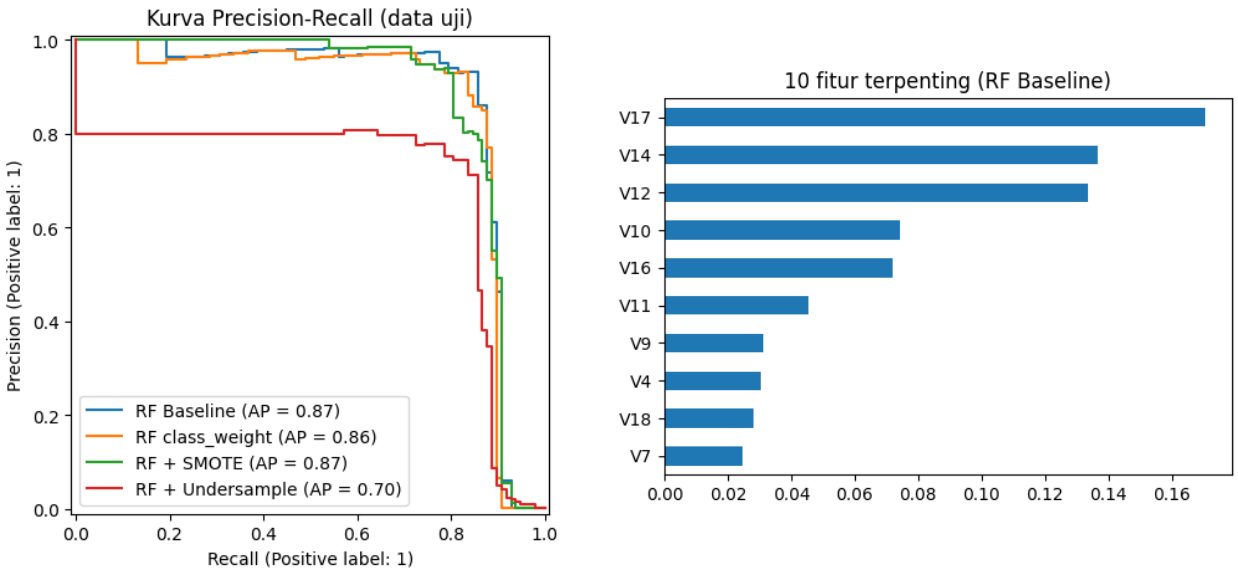
Tabel 5. Rincian confusion matrix (FP = false alarm, FN = fraud yang lolos)

Model	TN	FP	FN	TP
RF Baseline	56.859	5	18	80
RF class_weight	56.861	3	26	72
RF + SMOTE	56.848	16	17	81
RF + Undersample	54.827	2.037	8	90

4.2 Visualisasi perbandingan metrik



Gambar 3. Perbandingan precision, recall, F1 (kiri) serta ROC-AUC dan PR-AUC (kanan)



Gambar 4. Kurva Precision-Recall seluruh model (kiri) dan 10 fitur terpenting RF Baseline (kanan)

Pada kurva precision-recall, RF Baseline, RF class_weight, dan RF + SMOTE hampir berimpit, dengan *average precision* (AP) masing-masing 0,87, 0,86, dan 0,87, sedangkan kurva RF + Undersample berada jauh di bawahnya (AP 0,70; precision hanya sekitar 0,8 bahkan pada recall rendah). Menurut RF Baseline, tiga fitur terpenting adalah **V17, V14, dan V12**.

4.3 Mengapa akurasi saja tidak cukup?

Sebagai pembanding, dibuat model *dummy* yang selalu menebak transaksi normal. Model ini meraih akurasi **0,9983** namun **recall fraud = 0**: tidak satu pun penipuan terdeteksi. Karena kelas normal mendominasi hampir seluruh data, akurasi nyaris tidak mengukur kemampuan mendeteksi fraud.

Tabel 6. Akurasi dibandingkan recall fraud

Model	Akurasi	Recall fraud
RF Baseline	0,9996	0,8163
RF class_weight	0,9995	0,7347
RF + SMOTE	0,9994	0,8265
RF + Undersample	0,9641	0,9184
Dummy (selalu normal)	0,9983	0,0000

Model dummy memiliki akurasi lebih tinggi daripada RF + Undersample (0,9641) yang justru menangkap 92% fraud. Selisih akurasi di antara tiga model teratas pun kurang dari 0,02 poin persentase (0,9996 vs 0,9994), sehingga perbedaan kualitas yang sebenarnya tidak terlihat. Karena itu evaluasi harus berfokus pada precision, recall, F1, dan AUC untuk kelas fraud.

5. Analisis Perbandingan

1. **Baseline sudah kuat.** Tanpa penanganan apa pun, Random Forest mendeteksi 80 dari 98 fraud dengan hanya 5 *false positive* dan mencapai F1 tertinggi (0,8743). Penanganan imbalance tidak otomatis memperbaiki hasil.
2. **class_weight paling "hati-hati".** Precision tertinggi (0,9600; hanya 3 false positive) tetapi recall terendah (0,7347; 26 fraud lolos). Model lebih jarang menandai fraud, sehingga false alarm sedikit namun lebih banyak penipuan terlewat.
3. **SMOTE: recall naik tipis, precision turun.** Recall naik dari 0,8163 menjadi 0,8265 (hanya 1 fraud tambahan tertangkap), sementara false positive naik dari 5 menjadi 16, sehingga F1 (0,8308) lebih rendah daripada

baseline. ROC-AUC dan PR-AUC SMOTE sedikit lebih tinggi, tetapi selisihnya sangat kecil (0,0014 dan 0,0013) sehingga belum tentu bermakna. Penyebab yang masuk akal: dengan hanya 394 fraud di data latih, sampel sintetis hasil interpolasi dapat jatuh di wilayah yang beririsan dengan transaksi normal, sehingga batas keputusan bergeser dan false positive bertambah.

4. **Undersampling: recall tertinggi, tetapi tidak praktis.** Hanya 8 fraud yang lolos (recall 0,9184), namun 2.037 transaksi normal ikut ditandai fraud; dari 2.127 prediksi fraud hanya 90 yang benar (precision 0,0423). Model hanya melihat 394 contoh normal saat latih sehingga tidak mengenali keragaman transaksi normal. Selain itu, model dilatih pada proporsi 50:50 sedangkan data uji 99,8% normal, sehingga threshold 0,5 menjadi terlalu longgar.
5. **ROC-AUC bisa menyesatkan.** Undersampling memiliki ROC-AUC tertinggi (0,9777) tetapi PR-AUC terendah (0,6953). ROC-AUC memakai *false positive rate* (2.037 / 56.864 ≈ 3,6%) yang tampak kecil karena jumlah transaksi normal sangat besar, sedangkan precision dan PR-AUC langsung menunjukkan bahwa sebagian besar peringatan adalah alarm palsu. Pada data tidak seimbang, PR-AUC dan F1 lebih jujur daripada ROC-AUC.
6. **Pemilihan model bergantung pada biaya kesalahan.** Untuk keseimbangan terbaik antara fraud tertangkap dan alarm palsu, pilih **RF Baseline** (F1 tertinggi). Bila fraud yang lolos jauh lebih mahal dan tersedia tim peninjau manual untuk alarm tambahan, **RF + SMOTE** dapat dipertimbangkan (keunggulan recall atas baseline hanya 1 fraud, sehingga tipis). Bila gangguan terhadap pelanggan sah harus diminimalkan, pilih **RF class_weight**. **RF + Undersample** tidak layak dipakai dengan threshold bawaan.

6. Kesimpulan dan Keterbatasan

Kesimpulan

- Dataset sangat tidak seimbang (fraud 0,17%), sehingga akurasi tidak informatif dan evaluasi harus memakai precision, recall, F1, serta PR-AUC.
- Random Forest tanpa penanganan imbalance sudah memberi F1 terbaik (0,8743). SMOTE dan `class_weight` hanya menggeser *trade-off* precision-recall tanpa peningkatan kualitas yang jelas, sedangkan undersampling sangat menurunkan precision.
- Pemilihan teknik penanganan imbalance sebaiknya didasarkan pada biaya kesalahan yang berbeda antara fraud yang lolos dan alarm palsu, bukan pada anggapan bahwa resampling selalu lebih baik.

Keterbatasan

1. **Data uji kecil dan satu kali split.** Data uji hanya memuat 98 fraud, sehingga selisih kecil antar model (misalnya baseline vs SMOTE) belum tentu signifikan. *Stratified cross-validation* akan memberi estimasi yang lebih stabil.
2. **Threshold tetap 0,5.** Penyetelan threshold berdasarkan kurva precision-recall dapat memperbaiki trade-off, terutama untuk model undersampling.
3. **Tumpang tindih data latih dan uji.** Akibat duplikat pada dataset asli, 344 baris data uji (0,60%) identik dengan baris di data latih, termasuk 8 dari 98 fraud uji. Karena recall hanya dihitung pada fraud, nilainya bisa sedikit terlalu optimistis (paling banyak ≈ 8 poin persentase). Evaluasi pada data uji tanpa duplikat akan lebih ketat.
4. **Tanpa tuning dan model boosting.** Hyperparameter Random Forest tidak dituning, dan model boosting (XGBoost/LightGBM) belum dibandingkan.

Implementasi lengkap (kode, output, dan visualisasi) tersedia pada notebook 5054251035_Fauzan_Tamma_Harish_Kunfaza_Tugas_Ensemble.ipynb. Seluruh eksperimen memakai `random_state=42` *agar dapat direproduksi.*