

LAPORAN PRAKTIKUM 2 PREPROCESSING DATA

Fauzan Tamma Harish Kunfaza / 5054251035

1. Tujuan Praktikum

- Mengeksplorasi struktur dan kualitas data awal (EDA) sebelum diolah lebih lanjut.
- Mengidentifikasi dan menangani nilai yang hilang (missing values) pada dataset.
- Memeriksa dan menangani data duplikat.
- Mendeteksi dan menangani outlier agar tidak mendistorsi analisis.
- Melakukan transformasi data: encoding variabel kategorikal dan normalisasi variabel numerik.
- Menghasilkan dataset yang bersih dan siap digunakan untuk analisis atau pemodelan machine learning.

2. Dataset yang Digunakan

Dataset yang digunakan adalah train.csv dari studi kasus House Prices, yang berisi data karakteristik rumah tinggal (luas bangunan, kualitas material, tahun dibangun, lokasi/lingkungan, fasilitas, dan lain-lain) beserta harga jualnya.

Keterangan	Nilai
Jumlah baris (data) awal	1.460
Jumlah kolom awal	81 (80 fitur + 1 target SalePrice)
Kolom bertipe kategorikal (teks)	43
Kolom bertipe numerik	38

3. Langkah-Langkah Preprocessing

3.1 Eksplorasi Data Awal (EDA)

Pemeriksaan awal dilakukan menggunakan `df.info()` dan `df.describe()` untuk memahami tipe data tiap kolom serta ringkasan statistik (min, max, mean, kuartil) dari kolom-kolom numerik. Hasil EDA menunjukkan dataset memiliki campuran kolom numerik dan kategorikal, serta cukup banyak kolom dengan nilai kosong.

3.2 Penanganan Missing Value

Ditemukan 19 kolom dengan nilai kosong. Lima kolom dengan persentase missing tertinggi:

Kolom	Jumlah Missing	Persentase
PoolQC	1.453	99,5%
MiscFeature	1.406	96,3%

Kolom	Jumlah Missing	Persentase
Alley	1.369	93,8%
Fence	1.179	80,8%
MasVnrType	872	59,7%

Strategi penanganan dibedakan berdasarkan makna nilai kosong pada tiap kolom:

- Kolom kategorikal yang NA berarti "fitur tidak ada" (mis. PoolQC, Alley, GarageType, dsb.) → diisi label 'None'.
- Kolom numerik terkait fitur yang tidak ada (GarageYrBlt, MasVnrArea) → diisi 0.
- LotFrontage (nilainya benar-benar hilang, bukan "tidak ada") → diisi median per Neighborhood, karena luas lot sangat dipengaruhi lokasi.
- Electrical (1 baris kosong) → diisi modus (nilai tersering).

Hasil: seluruh missing value berhasil ditangani, total missing value tersisa = 0.

3.3 Pemeriksaan Data Duplikat

Pemeriksaan dengan `df.duplicated().sum()` menunjukkan tidak ada baris duplikat pada dataset ini, sehingga tidak diperlukan penghapusan data.

3.4 Deteksi dan Penanganan Outlier

Deteksi dilakukan secara visual menggunakan boxplot pada kolom SalePrice, GrLivArea, LotArea, dan TotalBsmtSF, serta scatter plot GrLivArea vs SalePrice. Dari scatter plot terlihat beberapa rumah dengan GrLivArea sangat besar (> 4000 sqft) namun harga jual rendah, sesuai dokumentasi resmi dataset, ini merupakan anomali penjualan, bukan pola wajar.

Penanganan dilakukan dengan dua cara:

- Menghapus 4 baris dengan GrLivArea > 4000 (anomali terdokumentasi).
- Capping/Winsorizing dengan metode IQR pada 19 kolom numerik kontinu lainnya, nilai di luar rentang $[Q1 - 1,5 \times IQR, Q3 + 1,5 \times IQR]$ dipangkas ke batas tersebut (bukan dihapus), agar jumlah data tetap terjaga.

Lima kolom dengan jumlah nilai yang paling banyak di-capping:

Kolom	Jumlah Nilai Di-cap
EnclosedPorch	208
BsmtFinSF2	167
ScreenPorch	116
MasVnrArea	98
LotFrontage	93

Hasil: 4 baris anomali dihapus (dataset menjadi 1.456 baris) dan total 1.140 nilai pada 19 kolom numerik kontinu berhasil di-capping ke batas wajar IQR.

3.5 Transformasi Data

- **Encoding kategorikal** dibedakan menjadi dua jenis:
 - Ordinal : 10 kolom kualitas bertingkat (mis. KitchenQual, ExterQual, BsmtQual) di-encode ke skala numerik 0–5 (None=0, Po=1, Fa=2, TA=3, Gd=4, Ex=5) agar urutan maknanya tetap terjaga.
 - Nominal: 33 kolom kategorikal tanpa urutan (mis. Neighborhood, MSZoning, SaleType) di-encode dengan One-Hot Encoding.
- **Normalisasi**: seluruh kolom fitur numerik dinormalisasi ke rentang [0, 1] menggunakan Min-Max Scaling, agar fitur berskala besar (mis. LotArea) tidak mendominasi fitur berskala kecil (mis. OverallQual). Kolom Id (identifikasi) dan SalePrice (target) tidak ikut dinormalisasi.

4. Hasil Akhir Preprocessing

Keterangan	Nilai
Ukuran dataset akhir	1.456 baris × 230 kolom
Total missing value	0
Total data duplikat	0
Kolom bertipe teks tersisa	0 (seluruh kolom numerik)
Rentang nilai fitur setelah normalisasi	0 – 1
File hasil	train_processed.csv

5. Kesimpulan

Melalui tahapan preprocessing yang telah dilakukan, dataset House Prices yang semula memiliki banyak nilai kosong, potensi outlier, dan variabel kategorikal berhasil diubah menjadi dataset yang bersih, konsisten, seluruhnya numerik, dan ternormalisasi. Penanganan missing value dilakukan secara kontekstual sesuai makna tiap kolom, outlier ditangani dengan kombinasi penghapusan anomali terdokumentasi dan capping IQR agar data tidak banyak berkurang, sedangkan encoding dan normalisasi mempersiapkan data agar siap digunakan pada tahap analisis atau pemodelan machine learning selanjutnya.